NOVAMARKET

Do evento ao insight

Evidências práticas do pipeline de Big Data

Kafka • Spark Structured Streaming • Data Lake • Airflow

Projeto acadêmico | UniFECAF | Novembro de 2026

Arquitetura do pipeline

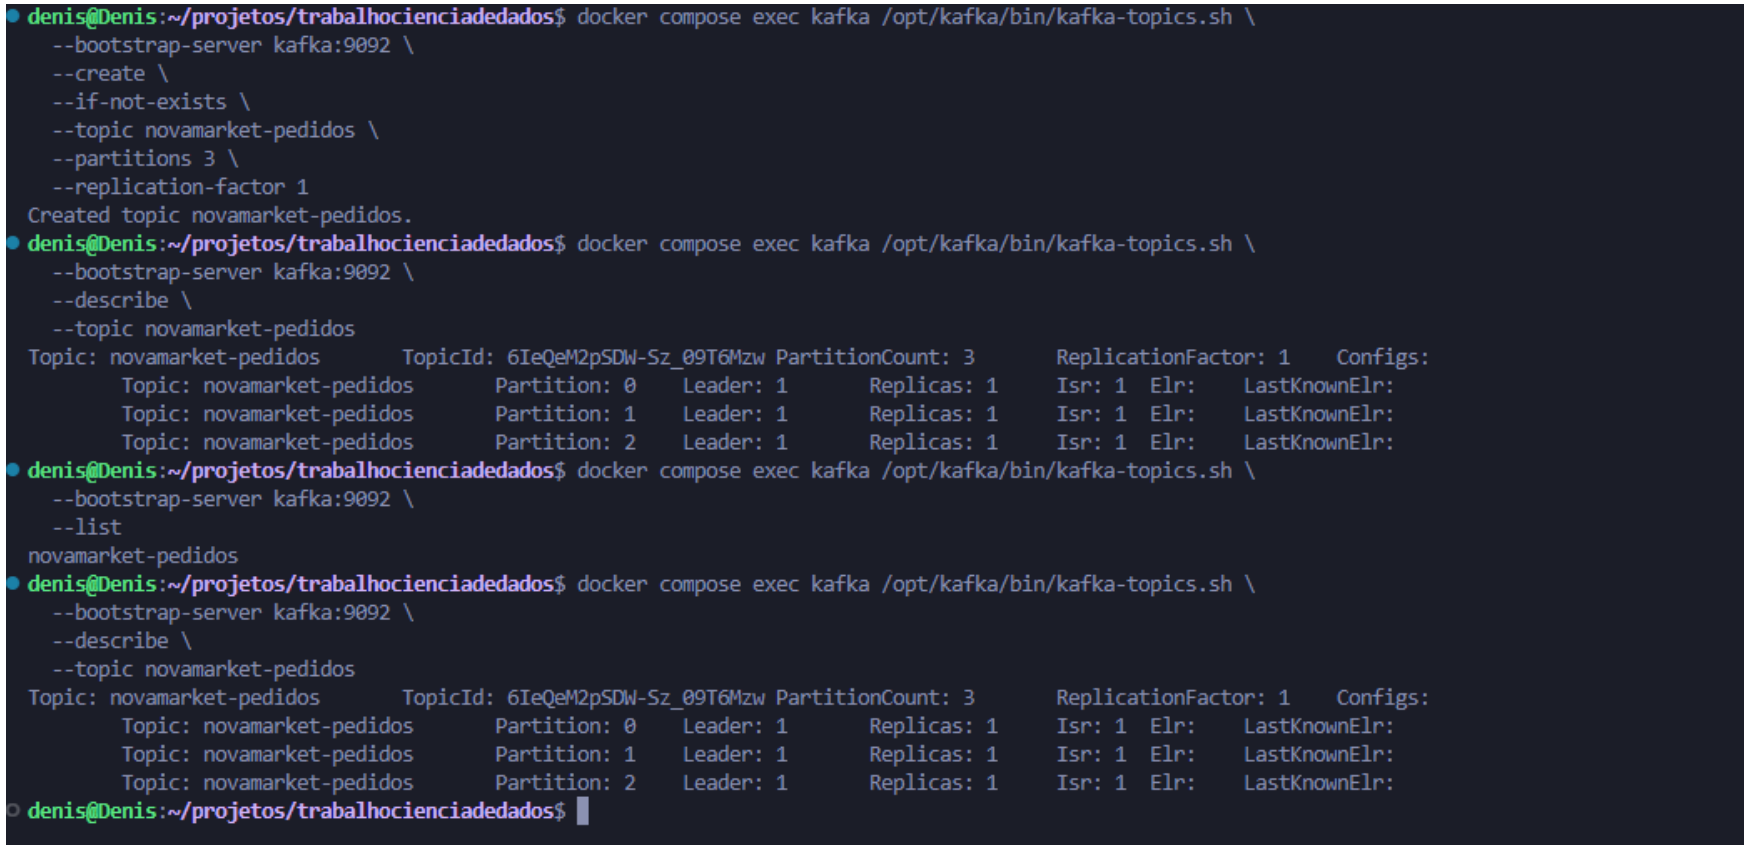
Visão resumida dos componentes e suas responsabilidades.



Airflow coordena check_input → process_data → quality_check → benchmark

01 · Kafka — tópico de pedidos

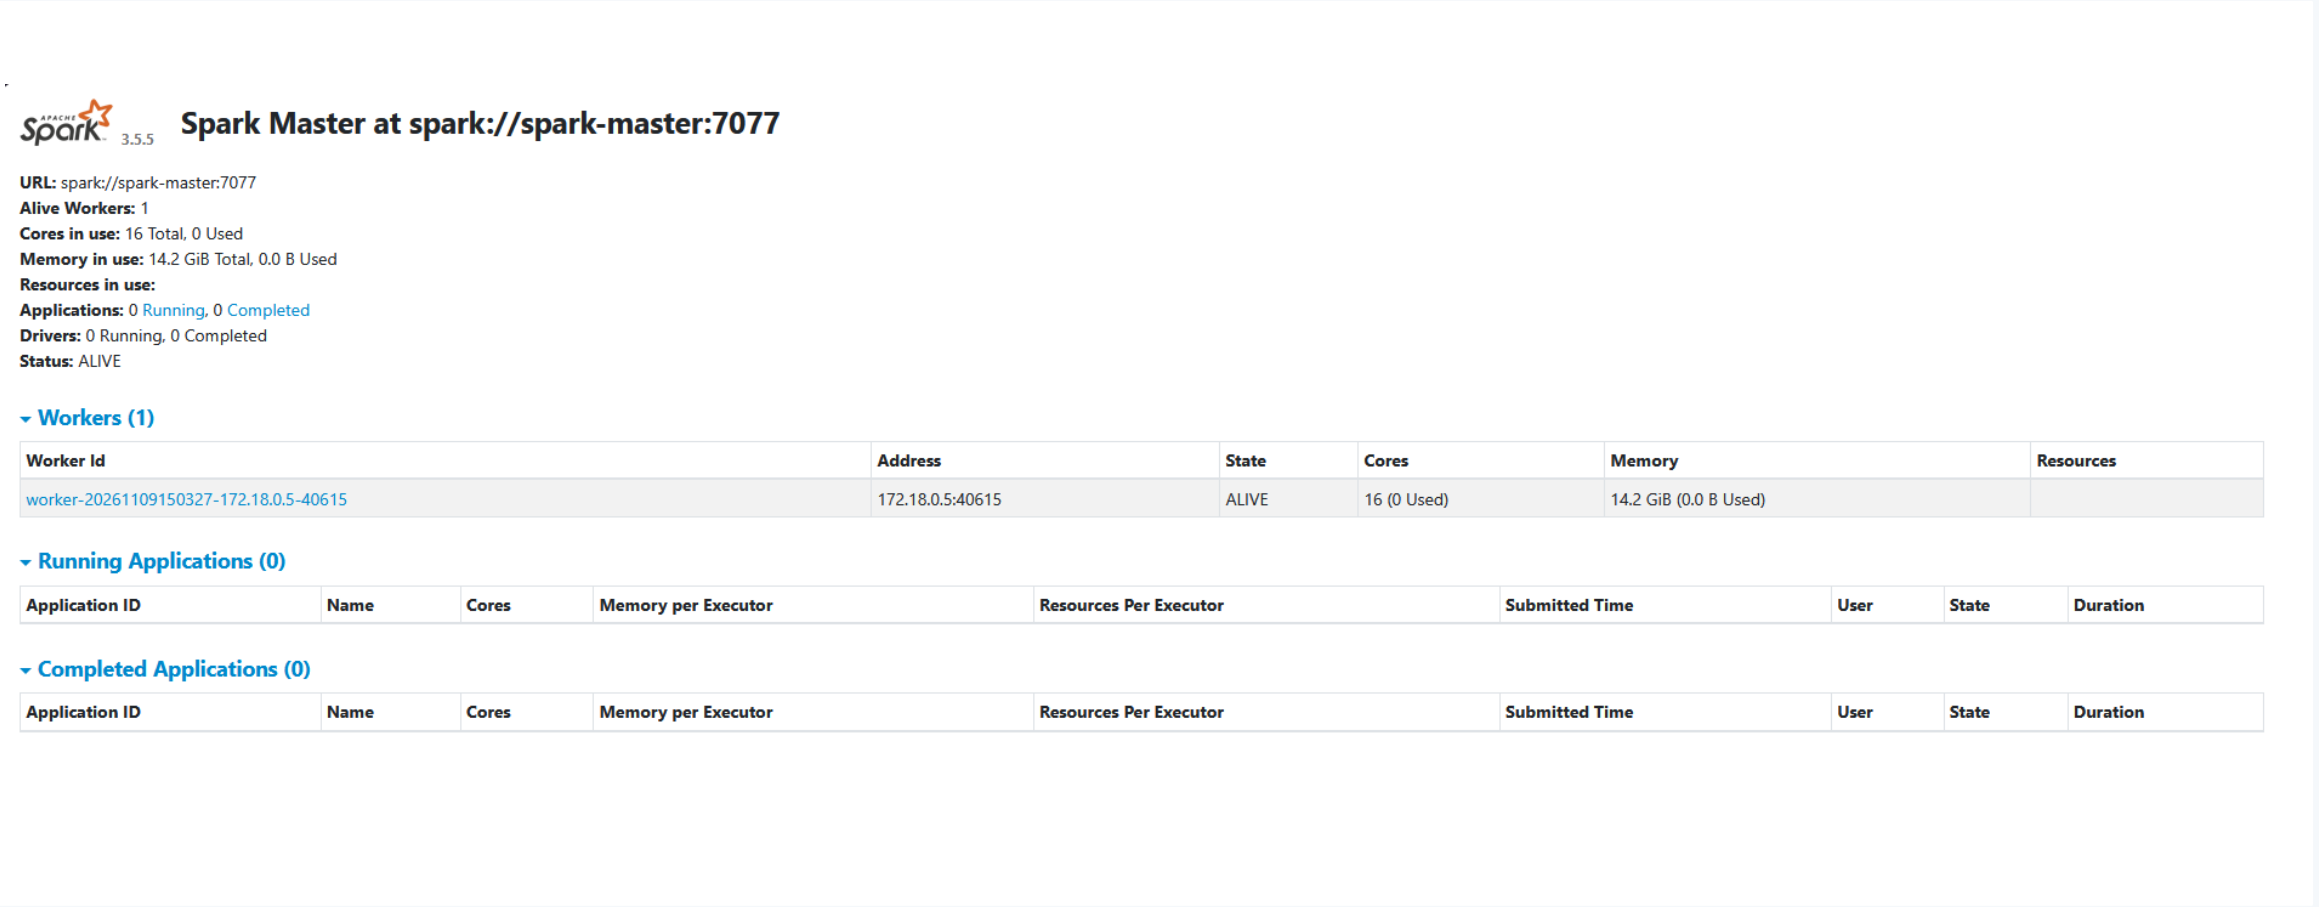
Produtor e tópico de eventos disponíveis no ambiente Docker.



Evidência: tópico novamarket-pedidos, 3 partições e replicação 1.

02 · Spark — cluster disponível

Master e Worker conectados, prontos para executar tarefas distribuídas.



Spark 3.5.5

Spark Master at spark://spark-master:7077

URL: spark://spark-master:7077
Alive Workers: 1
Cores in use: 16 Total, 0 Used
Memory in use: 14.2 GiB Total, 0.0 B Used
Resources in use:
Applications: 0 Running, 0 Completed
Drivers: 0 Running, 0 Completed
Status: ALIVE

Workers (1)

Worker Id	Address	State	Cores	Memory	Resources
worker-20261109150327-172.18.0.5-40615	172.18.0.5:40615	ALIVE	16 (0 Used)	14.2 GiB (0.0 B Used)	

Running Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration

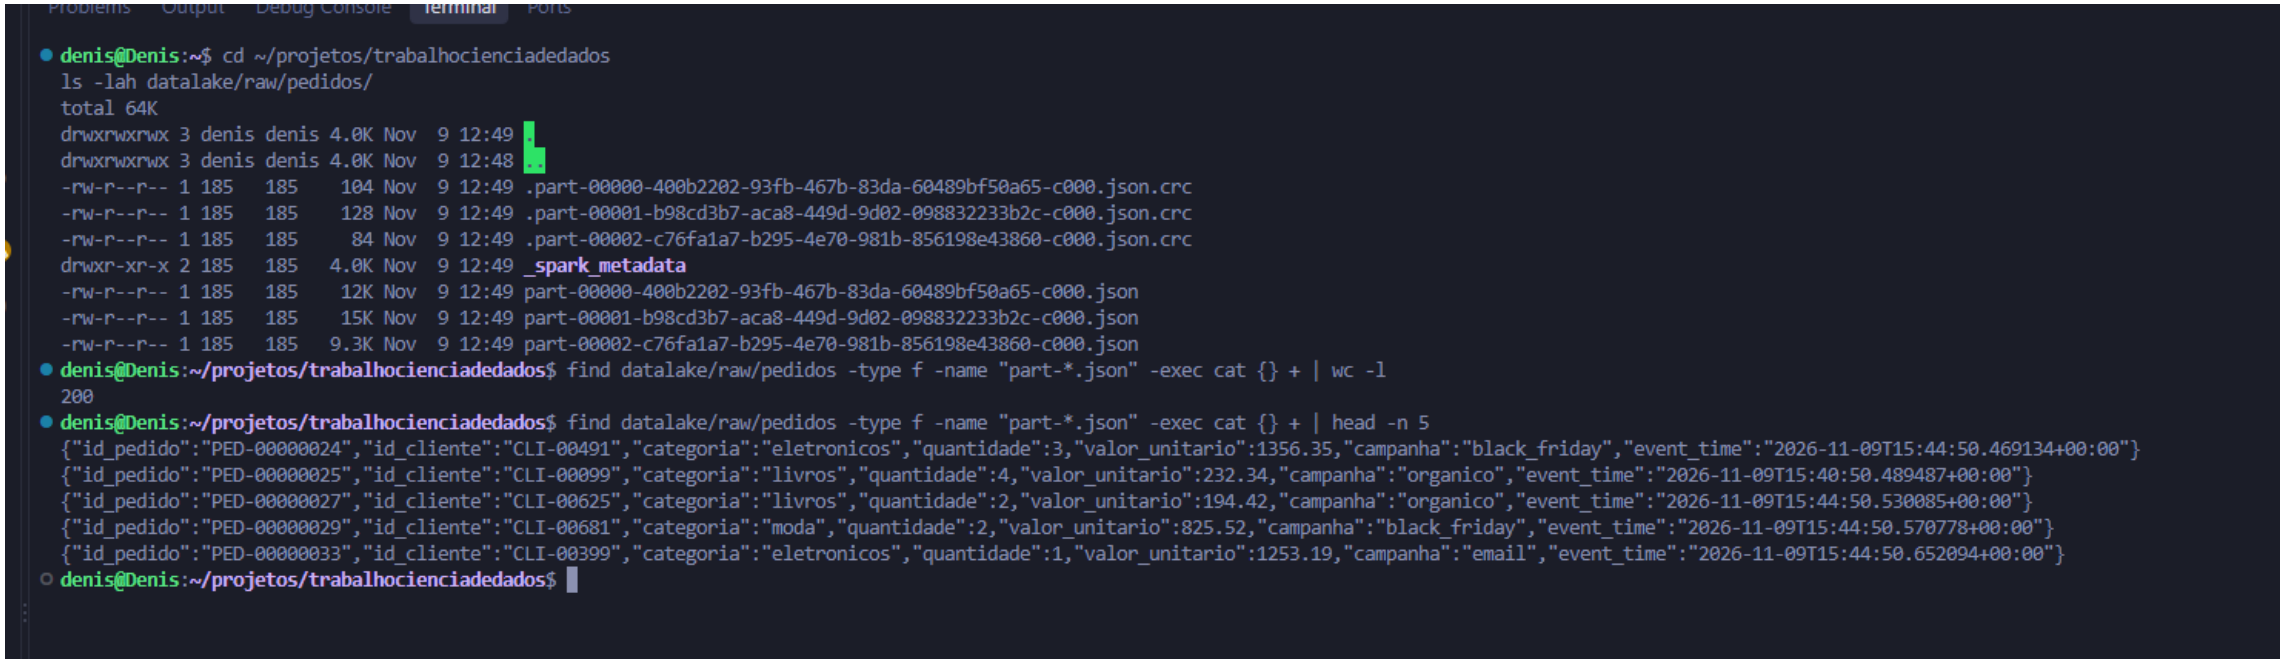
Completed Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration

Evidência: Spark 3.5.5 com um Worker ativo.

03 · Streaming — microbatches

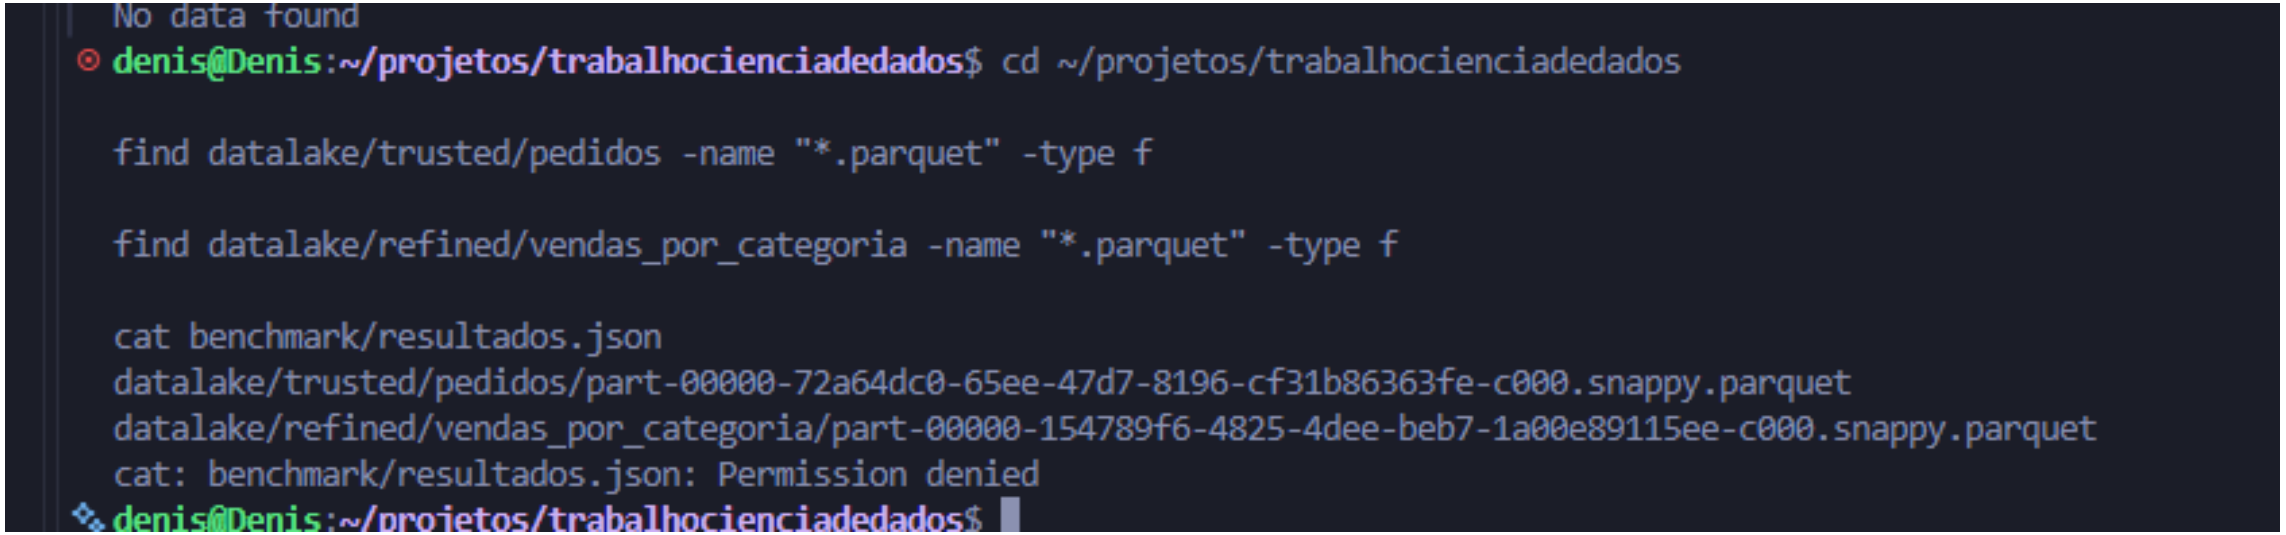
Leitura de eventos do Kafka e execução com checkpoints.



Evidência: progresso do streaming, offsets e processamento dos microbatches.

04 · Data Lake — persistência

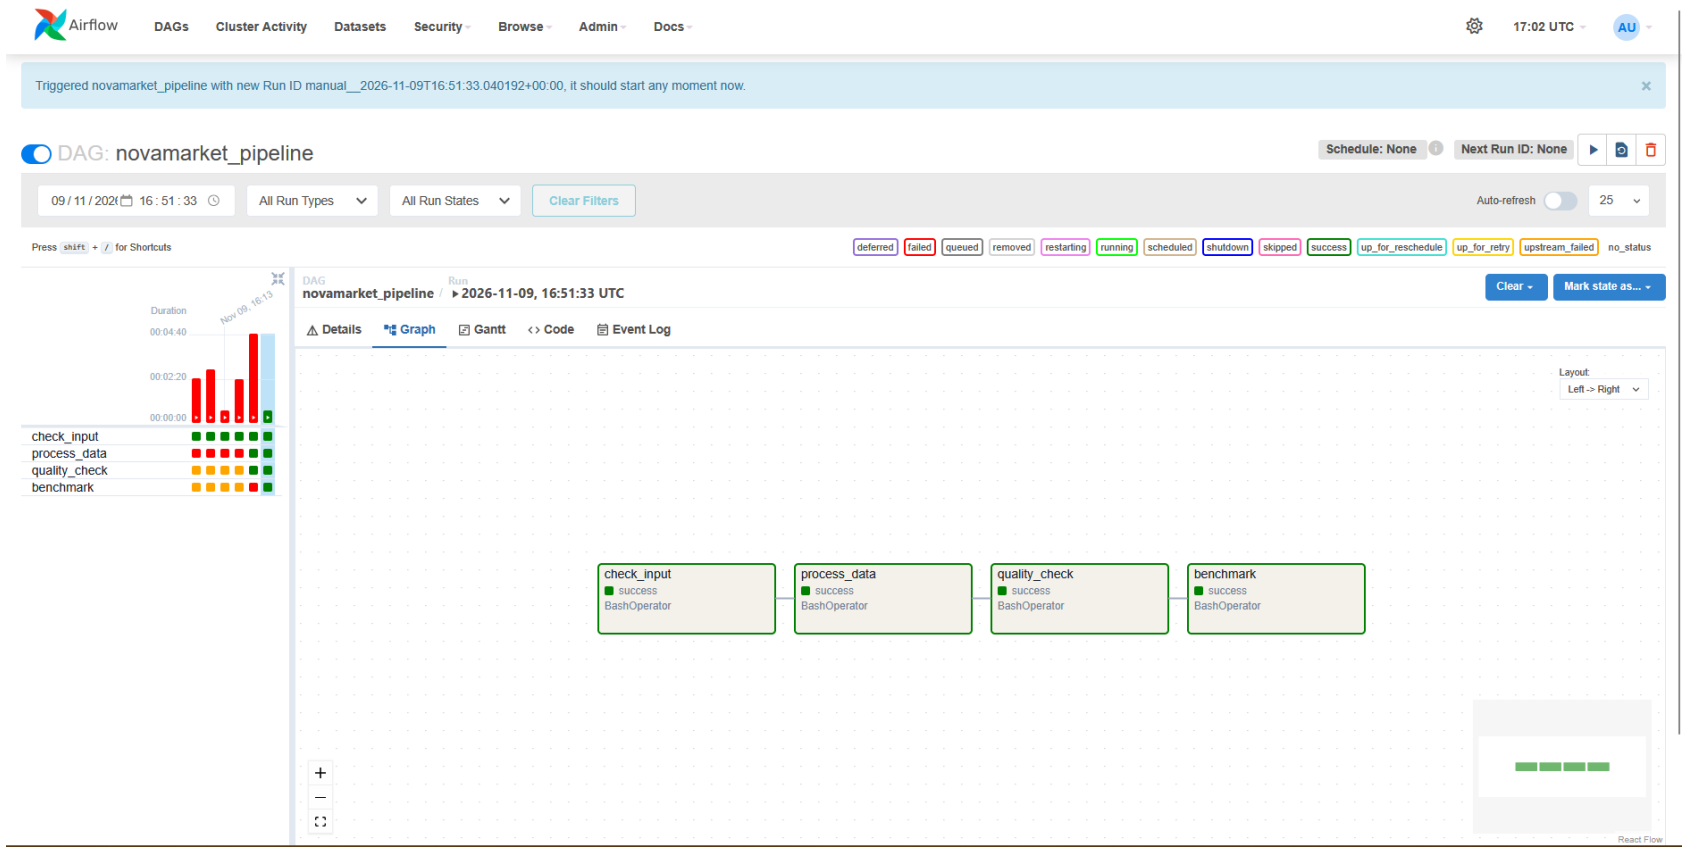
Camadas RAW, TRUSTED e REFINED com saídas materializadas.



Evidência: arquivos Parquet encontrados em TRUSTED e REFINED; RAW validada com 200 JSON.

05 · Airflow — execução concluída

DAG novamarket_pipeline executada de ponta a ponta.



Evidência: check_input, process_data, quality_check e benchmark com status success.

06 · Benchmark — resultado da execução

Comparação experimental de join convencional com broadcast join.



Evidência: JSON com tempos de 1,7516 s e 0,4577 s e redução de 73,87%.

Otimização — comparativo de tempos

Dados sintéticos de 300 mil registros; resultado analítico preservado.



−73,87% de tempo no experimento

Ambas as estratégias: 4 categorias e total de 149.850.000. Ganho não extrapolado para todo o pipeline.

Conclusão e evidências disponíveis

Resultados observados durante a execução do projeto no ambiente local.

200 eventos persistidos na RAW

3 camadas do Data Lake

4 / 4 tarefas Airflow concluídas

73,87% redução de tempo no benchmark

Repositório: github.com/denisddv/trabalhocienciadedados

Limites: POC local, Kafka com broker único e benchmark sintético de uma execução. Não representa disponibilidade de produção.